UNIVERSIDADE DE BRASÍLIA · FACULDADE DE TECNOLOGIA · ENGENHARIA DE PRODUÇÃO

Onde o prazo de entrega falha e quanto isso custa em satisfação

72,1%

dos atrasos acontecem com o vendedor postando dentro do prazo: o problema está no transporte

MVP: pipeline de dados em nuvem no Databricks, da coleta à decisão, sobre 99.441 pedidos do marketplace Olist

Tiago Andre Gondim · matrícula 231013476
EPR0050, Projeto de Sistemas de Produção 8 · Turma T01 · 2026.2
Prof. Dr. André Luiz Marques Serrano · Atividade individual

github.com/tiagondim-cpu/mvp-olist-pipeline

RESUMO EXECUTIVO

A hipótese caiu: o atraso nasce no transporte, não no vendedor

Seis perguntas respondidas sobre 96.470 pedidos entregues, de janeiro/2017 a agosto/2018, com o pipeline executado na nuvem

6,8%

dos pedidos entregues chegaram depois da data prometida (6.534 pedidos)

72,1%

dos atrasos com o vendedor postando no prazo: a hipótese H1 (vendedor) foi refutada

68%

dos clientes dão nota 1 ou 2 com 4 a 7 dias de atraso, contra 9% no prazo

O que a operação deve fazer, em ordem de retorno

- Cobrar a transportadora nas rotas críticas: SP→RJ sozinha responde por 17,6% de todos os atrasos
- Planejar os picos: três meses concentram 48% dos atrasos com 22% dos pedidos
- Calcular a data prometida por rota e contatar o cliente antes do quarto dia de atraso
- Programa de vendedores como alavanca secundária: no máximo 1,9 ponto percentual de ganho

MAPA DO PROJETO

O MVP percorreu o ciclo completo de experimentação do enunciado

Cada etapa do ciclo tem um artefato verificável no repositório

1. Ideia	2. Construir	3. Produto	4. Medir	5. Dados	6. Aprender
Problema, hipótese H1 e 6 perguntas	Coleta, modelagem e carga no Databricks	Job de 5 tarefas e repositório público	Qualidade e consultas SQL na gold	Tabelas, gráficos e resumo exportados	H1 refutada, discussão e autoavaliação

Viabilidade técnica

Pipeline executado ponta a ponta no Databricks Free Edition em cerca de 6 minutos, com 28 tabelas Delta persistidas no Unity Catalog.

Viabilidade financeira e desejabilidade

Custo zero no plano gratuito. As seis perguntas foram respondidas com número, discussão e decisão sugerida para o gestor de operações.

ETAPA 1 · OBJETIVO

Objetivo antes dos dados: onde agir primeiro quando o prazo falha

Problema do gestor de operações de um marketplace que não controla quem posta nem quem transporta

Hipótese H1

A maior parte dos atrasos nasce na postagem tardia do vendedor.

Critério fixado antes da análise: H1 se sustenta se mais da metade dos atrasos tiver origem no vendedor. Se verdadeira, um programa de vendedores seria a alavanca de maior retorno.

	Pergunta	Decisão que apoia
P1	Taxa de atraso e picos mês a mês	Capacidade para picos
P2	Origem: vendedor ou transporte	Onde agir
P3	Rotas críticas e efeito da distância	Renegociar transportadora
P4	Calibração da data prometida por UF	Recalibrar promessa
P5	Avaliação por faixa de atraso	Gatilho de contato
P6	Concentração das postagens tardias	Programa de vendedores

ETAPA 2 · COLETA

Coleta: base pública e anonimizada, baixada direto para a nuvem

Brazilian E-Commerce Public Dataset by Olist, versão 2 no Kaggle, licença CC BY-NC-SA 4.0, coletada em 21/10/2026

9

arquivos CSV relacionados

1,55 mi

linhas no total (126 MB)

99.441

pedidos de set/2016 a out/2018

0

bytes de dado bruto versionados no repositório

Como foi coletado

O notebook 01 baixa os arquivos com o pacote oficial kagglehub dentro do Databricks, grava os originais em um volume do Unity Catalog e registra arquivo, linhas, licença e data na tabela registro_coleta.

Ética e proteção de dados

Clientes e vendedores aparecem como códigos de 32 caracteres e o CEP só com 5 dígitos. Uso acadêmico, não comercial, compatível com a licença. O repositório publica o método, não os dados.

Arquitetura medalhão: cada camada com uma função e uma verificação

Cinco notebooks encadeados em um job do Lakeflow Jobs, em computação serverless

Bronze

9 tabelas Delta

Cópia fiel, tudo como texto

Trava: Contagens iguais às dos arquivos

Silver

8 tabelas

Tipagem, deduplicação, 19 regras de negócio

Trava: Chaves únicas, nenhum pedido perdido

Gold

7 tabelas + 3 de qualidade

Modelo dimensional e catálogo

Trava: Catálogo idêntico ao modelo

Análise

6 perguntas

SQL e gráficos

Trava: Resumo gravado na nuvem



Job executado no Databricks: as cinco tarefas em sequência, todas concluídas, em cerca de 6 minutos. Se qualquer verificação falha, o job para.

Regras que mudam a leitura dos resultados: atraso por data-calendário (RN04), uma avaliação por pedido (RN10), pontos de geolocalização fora do Brasil descartados (RN12) e rota só para pedidos de um único vendedor (RN14).

Três fatos, quatro dimensões e um catálogo vivo na plataforma

Cada fato guarda um único grão, para que nenhum valor seja contado duas vezes

fato_pedido

1 linha por pedido · 99.441

fato_item_pedido

1 linha por item · 112.650

fato_pagamento

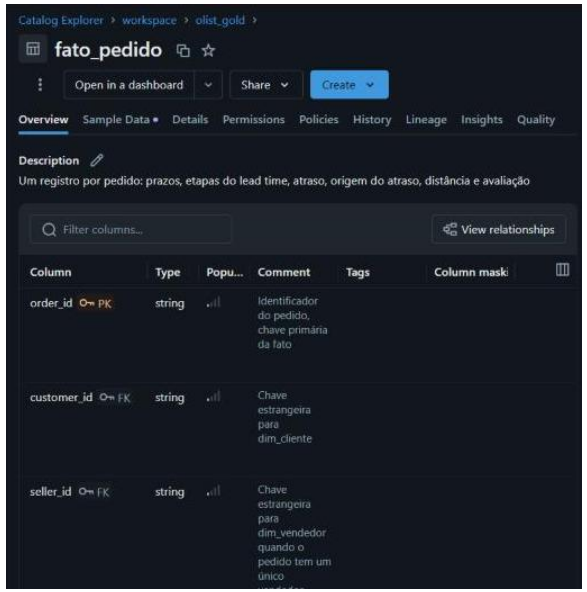
1 linha por pagamento · 103.886

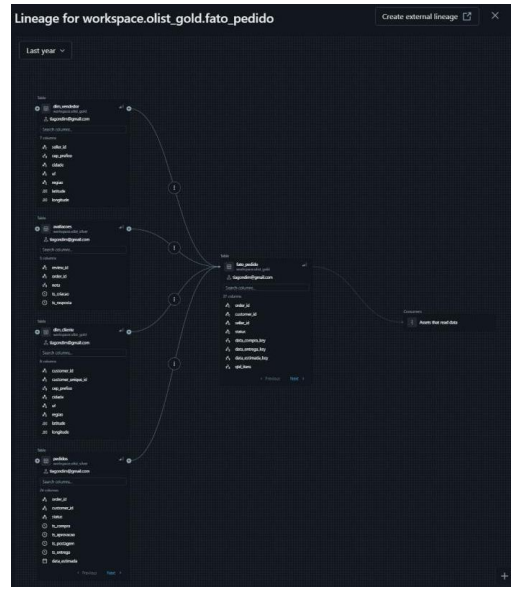
dim_cliente

dim_vendedor

dim_produto

dim_data





No Unity Catalog: colunas com chaves e descrições vindas do catálogo (esquerda) e a linhagem que a plataforma registrou sozinha (direita).

75 atributos catalogados

Tipo, domínio, obrigatoriedade e linhagem num único arquivo, que o pipeline grava no Unity Catalog e usa para conferir cada coluna.

Base íntegra: nenhuma regra bloqueante violada, falhas isoladas

52 colunas de origem, 75 atributos do modelo e 21 regras avaliados, com resultados gravados em tabelas da gold

0

chaves duplicadas e registros órfãos nas fatos

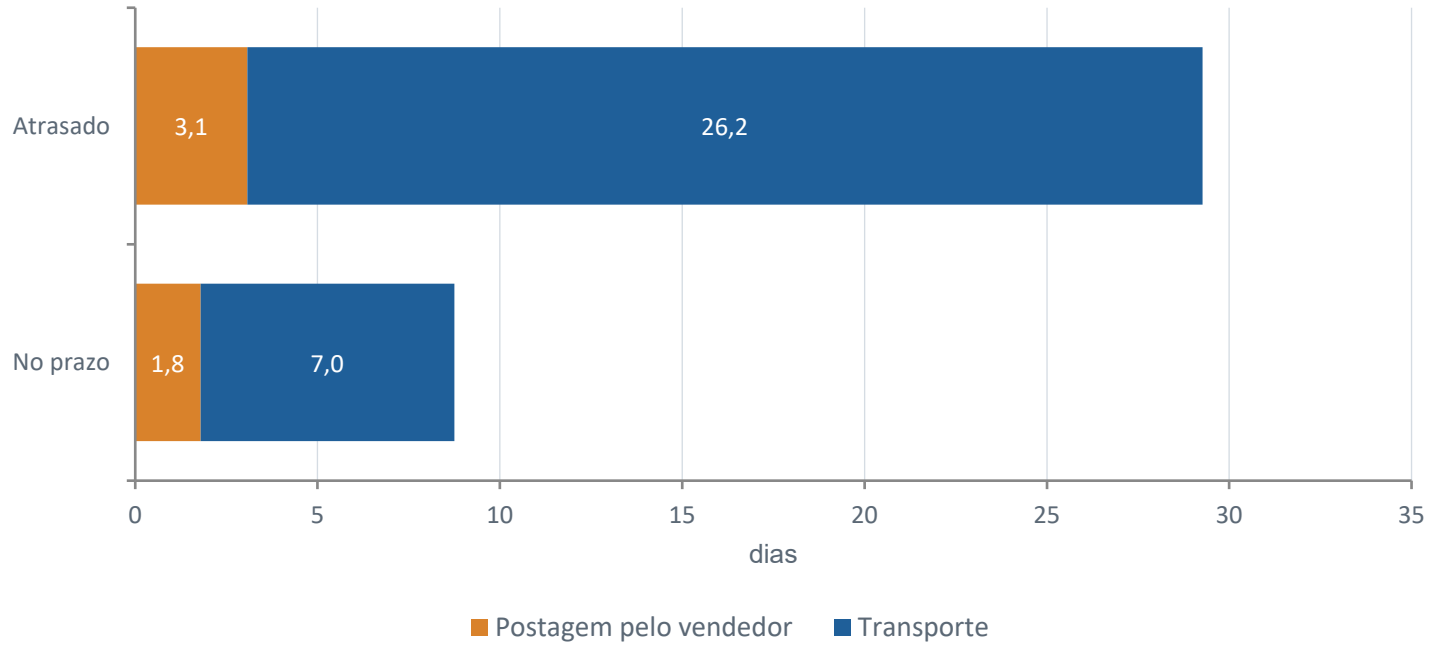
1,4%

dos pedidos entregues com etapa de duração negativa, tratados pela RN07

Dimensão	Achado	Volume	Tratamento
Unicidade	Pedido com mais de uma avaliação	547	Mantida a mais recente
Consistência	Etapa do lead time com duração negativa	1.373	Fora da decomposição
Acurácia	Ponto de geolocalização fora do Brasil	42	Descartado
Completude	Produto sem categoria	610	Categoria explícita
Conformidade	Atraso fora de ±60 dias (até 188)	113	Mantido: atraso real
Atualidade	Última compra em 17/10/2018	8 anos	Vale para 2017 e 2018

H1 refutada: o transporte, não a postagem, é a etapa que explode

Mediana de cada etapa do lead time, em dias, para pedidos atrasados e entregues no prazo



72,1%

dos atrasos com postagem no prazo (4.695 de 6.509): origem no transporte

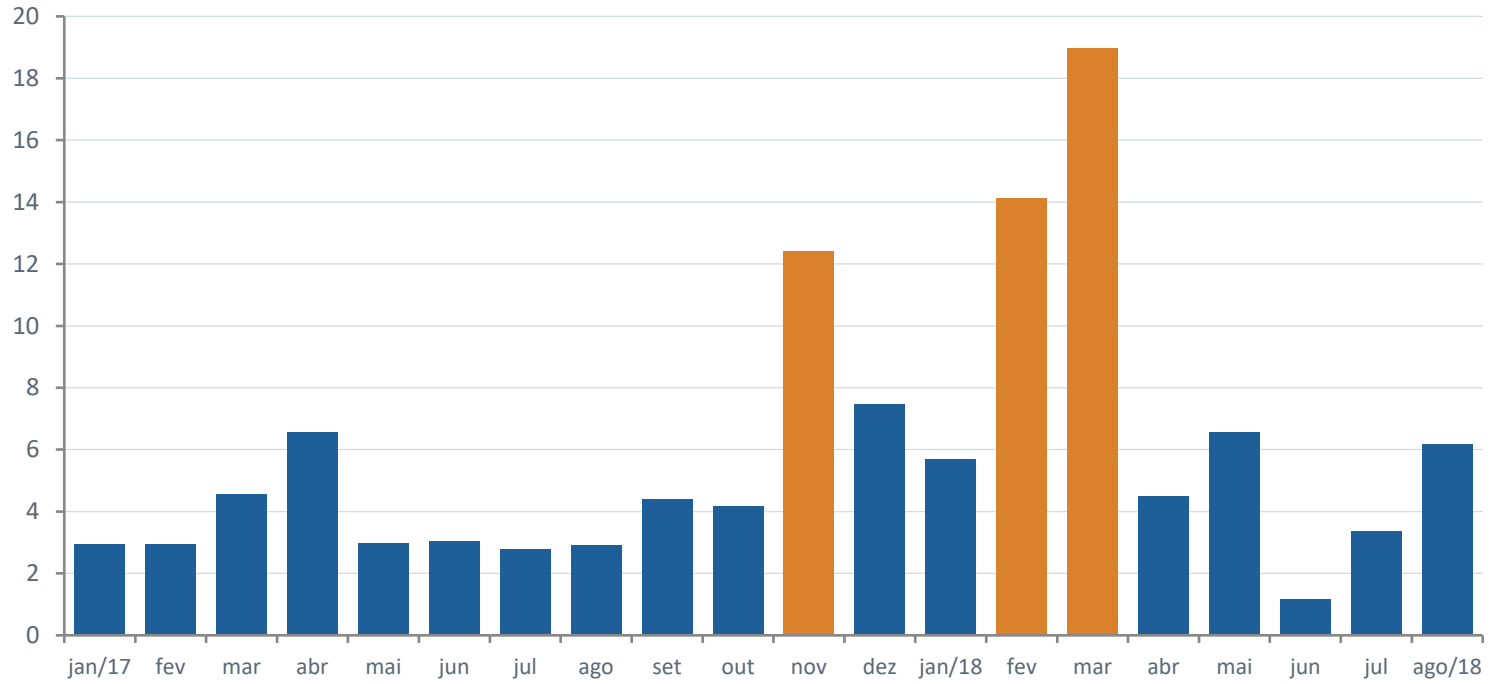
1,9 p.p.

é o ganho máximo se todos os vendedores postassem em dia: de 6,8% para 4,9%

O prazo prometido é igual nos dois grupos (23 e 24 dias). Os atrasados não tiveram promessa mais apertada: tiveram um transporte 3,7 vezes mais lento.

O atraso se concentra em três meses e em uma rota

Taxa de atraso por mês da compra (%) e rotas com maior peso no total de atrasos



48%

dos atrasos em nov/2017, fev/2018 e mar/2018, meses com 22% dos pedidos

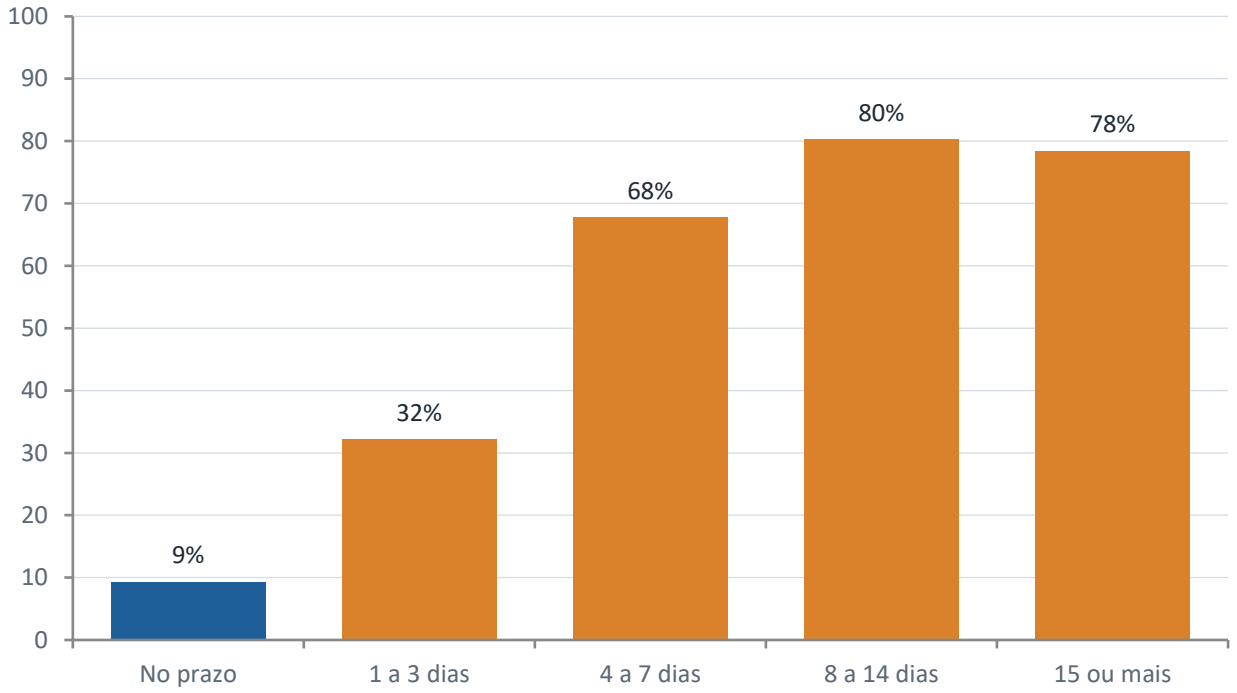
17,6%

de todos os atrasos vêm da rota SP→RJ (14,2% de atraso em 8.048 pedidos)

Novembro foi pico de demanda (Black Friday, +63% de pedidos). Fevereiro e março não tiveram aumento de volume; a greve dos Correios iniciada em 12/03/2018 é hipótese compatível, não testada.

A promessa não está calibrada, e o cliente pune a partir do quarto dia

Percentual de avaliações com nota 1 ou 2 por faixa de atraso



Folgada demais no Norte

AC, AP, RO e AM: prometem de 38 a 48 dias para entregas de 18 a 26, com menos de 4% de atraso.

Insuficiente no Nordeste e no Rio

AL chega a 21,4% de atraso; o RJ soma cerca de 1.500 atrasos, 23% do total.

Os pedidos atrasados são 6,7% dos avaliados e geram 32% das avaliações ruins. O gatilho de ação tem de ser a previsão do atraso, antes do primeiro dia.

Ordem de ação: transporte, promessa e, por último, vendedores

Um quarto dos vendedores gera 80% das postagens tardias, mas a postagem explica pouco do atraso

1	**Transportadora nas rotas críticas**	Acordo de nível de serviço em SP→RJ e nas rotas para o Nordeste	**4,9 p.p. da taxa vêm do transporte**
2	**Contingência para picos**	Capacidade extra antes de novembro e plano para paralisações	**48% dos atrasos em 3 meses**
3	**Promessa por rota**	Prazo pelo percentil 90 do transporte, validado em teste A/B	**Atraso de 2,8% a 21,4% entre UFs**
4	**Contato proativo**	Alerta quando a entrega prevista passar da data prometida	**68% de notas ruins com 4 a 7 dias**
5	**Programa de vendedores**	162 de 615 vendedores geram 80% das postagens tardias	**Ganho máximo de 1,9 p.p.**

VALIDAÇÃO

Duas implementações independentes chegaram aos mesmos números

Uma segunda versão em pandas, escrita só a partir das regras de negócio, sem acesso aos notebooks do Databricks

255 / 256

comparações dentro da tolerância, nenhuma divergência

1 erro

encontrado e corrigido no pipeline graças à conciliação

O que a conciliação pegou

Na primeira rodada, as faixas de distância diferiam em 1 a 4 pedidos. A causa: o pipeline arredondava a distância antes de classificar, e um pedido a 99,96 km virava 100,0 km e mudava de faixa. Removido o arredondamento, as faixas passaram a coincidir exatamente.

A diferença restante é de 1 pedido em P2: um atraso sem data de postagem, que o Databricks deixa sem origem e o pandas atribui ao transporte. Está documentada no relatório de conciliação.

Seis perguntas respondidas; duas com limites declarados

Respostas às quatro questões de autoavaliação do enunciado

Respondido

As seis perguntas. Parciais: a causa dos picos de fevereiro e março (P1) e o efeito da promessa longa na conversão (P4).

Limites dos dados

Sem identificação da transportadora, uma postagem por pedido, dados até 2018 e meses finais censurados, avaliação observacional.

Faria diferente

Origem do atraso contrafactual em vez da regra binária, e o transporte modelado por percentis desde a silver.

Para uso contínuo

Ingestão incremental, job agendado com alertas por rota, modelo preditivo de atraso e painel para o gestor.

SÍNTESE

A intuição apontava para o vendedor.
Os dados apontaram para o transporte.

Pipeline em nuvem ponta a ponta, 28 tabelas Delta, 75 atributos catalogados, qualidade verificada em 21 regras e números confirmados por uma segunda implementação. O que falta para decidir está nomeado: dados de transportadora e um teste controlado de cada ação.

Tiago Andre Gondim · 231013476 · EPR0050 T01 · github.com/tiagondim-cpu/mvp-olist-pipeline